Portfolio project · Production-ready at small scale

TeleCopilot AI v2

Feasibility Study & Execution Plan

From a RAG demo to an open-source, omnichannel CSR agent-assist product

دراسة جدوى وخطة تنفيذ: من RAG demo لمنتج Agent Assist حقيقي
لموظفي خدمة العملاء، بموديلات Open-Source

محتويات التقرير

1	الملخص التنفيذي
2	تقييم المشروع الحالي
3	المشكلة من ناحية البيزنس
4	المنافسين: المميزات والأسعار
5	الخطوة 1: القنوات وشاشة الموظف
6	الخطوة 2: قاعدة المعرفة من بيانات حقيقية
7	الخطوة 3: مسار المهارات
8	الموديلات والهاردوير والتكلفة: Local أولًا
9	القياس: جودة كل خدمة + KPIs + Load Testing
10	المعمارية وهيكلة المشروع
11	الجاهزية للإنتاج
12	طريقة الشغل
13	الـ Milestones والمخاطر

Prepared October 2026 · v3 (25 Oct 2026: milestone order, 5 models, design-first, code quality, bilingual UI) · Learning + portfolio project (telecom) · Author: Ziad Ashraf · Repo: TeleCopilotAi (branch master, commit 5a3b0e7)

1. الملخص التنفيذي

Executive Summary

الفكرة بتحل مشكلة حقيقية وموجودة في السوق: منتجات زي Google CCAI Agent Assist وSalesforce Einstein وZendesk AI Copilot وMicrosoft Copilot for Service بتتباع لنفس الهدف. شركات الاتصالات بتقيس النجاح بـ **AHT** (متوسط وقت المكالمة)، و**FCR** (حل المشكلة من أول تواصل)، ووقت تدريب الموظف الجديد، وأخطاء الـ compliance.

المشروع الحالي **RAG knowledge assistant** قوي في الـ retrieval، لكنه لسه مش **agent-assist product**: الموظف بيكتب المشكلة بنفسه في شاشة منفصلة، ومفيش customer context ولا memory ولا قنوات ولا tickets. الخطة دي بتقفل الفجوة دي في 3 خطوات، وكل حاجة شغالة على موديلات open-source بننشرها بنفسنا.

1.00	0.61	RTX 2050	$0 → $10
Retrieval hit@3 today	Faithfulness today (weak)	Stage A runs on a 4 GB laptop GPU	Free tiers first, $10 cap

النطاق: المشروع ده للتعلّم والـ portfolio: Agent Assist لـ contact center شركة اتصالات واحدة.

الحكم النهائي (Verdict): المشروع ممكن تنفيذه — Feasible بنسبة عالية.

- تقنيًا: كل الأجزاء ليها بدائل open-source ناضجة (vLLM، BGE-M3، faster-whisper، LangGraph، MCP SDK).
- العائق الأساسي هو **الهاردوير المحلي** (RTX 2050، 4GB VRAM) و**كوتة الإنترنت**. القرار: **Local-first**. كل خدمة لازم تشتغل الأول على اللابتوب بموديلات صغيرة (3B GGUF≥) ونقيس جودتها وأقصى capacity ليها، وبعد كده ننقل لـ GPUs مجانية (Kaggle/Colab) ثم بحد أقصى $10.
- العائق التاني هو **الداتا**: مفيش داتا CRM أو محادثات حقيقية متاحة، فهنعمل synthetic data بجودة مراجَعة يدويًا، ونستخدم صفحات وPDFs حقيقية من مصادر عامة للـ KB.
- مستوى "production صغير" (20–100 موظف، شركة واحدة) يقدر يوصل لـ ~90% من الـ checklist. الـ 10% الباقية (SSO مؤسسي، تكامل حقيقي مع Siebel/Genesys، شهادات أمان) خارج نطاق الـ portfolio.

القرارات النهائية (اتاخدت 25 أكتوبر 2026)

#	Decision	Why
1	**Local-first:** every service works on the 4 GB laptop GPU first, with quality, business-KPI and load-test reports = the baseline. Then free cloud GPUs, then max **$10**	Proof of the base solution and its max capacity before spending anything
2	**Milestone order:** restructure → **UI + CRM data** → **KB & data pipelines** → models → generation → channels → agent → speech → hardening → cloud	UI defines the data; good data before any model
3	UI = **Reflex** (Python full-stack) agent desktop: inbox + conversation + customer 360 + copilot panel	Whole project stays in Python; matches how CSRs work
4	WhatsApp **simulator first** in the exact Meta Cloud API format; real API later on the free test number	Free, testable; switching = one adapter
6	**Design first:** each milestone starts with a design pack (architecture + sequence diagrams, ERD, explained decisions) approved by Ziad	Understand and approve before code
7	**Five open models** (LLM, embedding, reranker, ASR, vision/OCR) from the Hugging Face Hub, chosen in M3 on Egyptian dialect / code-switching / Franco evals	Real Egyptian usage, not only leaderboards
8	**Code quality:** SOLID, DRY, KISS/YAGNI, no anti-patterns, ruff; a report per ticket explaining what and why	Maintainable code you can read and learn from
9	**Bilingual UI** (Arabic RTL + English), clean style from the Figma "Chat UI" reference, no emojis/robot look	Real CSR tool for Egyptian teams
5	Voice: **both** live calls (browser WebRTC via LiveKit, no paid numbers) and recordings / WhatsApp voice notes	Covers the highest-volume channel at $0

2. تقييم المشروع الحالي

Current-State Audit

قريت الكود كله: حوالي 3,400 سطر Python في src/، و11 ملف tests، و3 notebooks للـ eval، وUI ثابتة (HTML/JS/CSS ~2,100 سطر).

Strengths ✓

- Clean layering: controller → service → repository, factories, DI, singletons
- Multi-format ingestion (HTML, XML, DOCX, scanned/Arabic PDF via OCR, live web)
- Hybrid retrieval: dense + BM25, RRF, rerank; filters by intent/format
- Structured JSON output + SSE streaming
- Langfuse tracing with latency, tokens and cost
- Real evaluation: ground truth, extraction metrics, RAGAS (AR + EN)
- Docker Compose + GitHub Actions CI

Gaps ✗

- UI is a single "type the problem" form — not how CSRs work
- No customer, ticket, conversation or channel model; no database besides Qdrant
- No memory (session or customer), no tools/actions, no agent loop
- Fully tied to paid APIs (Cohere, Gemini); no provider abstraction
- KB is 10 synthetic docs (~2 MB each, padded) + 4 scraped pages
- Faithfulness 0.61, Arabic 0.43; judge = same model (biased)
- No auth, PII masking, audit log, rate limits; CORS *
- Startup ingestion inside the API process; no job queue

Scorecard against a small-production bar

Area	Today	Target v2	Note
Retrieval quality	Good	Keep ≥ 0.9 hit@3 on a bigger real KB	Small KB makes 1.00 easy
Answer grounding	Weak	Faithfulness ≥ 0.85	Stricter prompt, claim checking, citations per sentence
Product fit (CSR workflow)	Missing	Agent desktop + channels	Biggest change
Agent / tools / memory	Missing	LangGraph + 8–10 tools + 3 memory types	—
Speech	Missing	Recordings + voice notes → transcript → assist	Egyptian WER measured
Open-source deploy	Missing	vLLM / llama.cpp / TEI profiles	Learning goal
Security & compliance	Missing	Auth, roles, PII masking, audit	Must-have for any real pilot
Eval & CI	Partial	Harness + regression gate	Notebooks → scripts
Code structure	Good	Modular packages	Restructure, don't rewrite

3. المشكلة من ناحية البيزنس

يوم الموظف في الحقيقة

الموظف بيبدأ الشيفت بـ login على الـ **agent desktop** (Genesys / Avaya / NICE / Salesforce Service Cloud / Zendesk، أو CRM داخلي زي Siebel في شركات الاتصالات المصرية). بيحط حالته "Available"، والـ **ACD / routing** بيوزّع عليه المكالمات والشاتات والتيكتس حسب المهارة واللغة. لما تواصل يوصل، بتفتح قدامه شاشة فيها بيانات العميل (customer 360): الرقم، الباقة، الرصيد، آخر فواتير، والتيكتس المفتوحة.

الحل الأساسي اللي بيتعمل النهاردة (The naive baseline)

Step	Baseline (no AI)	Typical time	With TeleCopilot v2
Understand problem	Listen / read, ask follow-ups	30–90 s	Live intent + summary from the transcript
Look up customer	Click through CRM tabs, billing system	30–60 s	Tools fetch plan, bills, outages, past tickets automatically
Find the policy	Keyword search KB, read a long PDF, ask a team lead	60–180 s	Grounded answer + citation + next-best-action
Write the reply	Type or use canned macros	30–90 s	Draft reply in the customer's dialect, one-click insert
Take action	Create ticket, apply credit, escalate	30–120 s	Pre-filled action, CSR approves
Wrap-up (ACW)	Write notes, pick disposition code	30–90 s	Auto summary + disposition, CSR confirms

القيمة المتوقعة: تقليل AHT بنسبة 10–25% (أرقام منشورة من vendors زي Google وSalesforce، ومحتاجة تتأكد عندنا بالـ eval)، وأكبر توفير بييجي من الـ **after-call work** والبحث في السياسات. الموظف الجديد بيبقى productive أسرع، والـ supervisor بيشوف معدل قبول الاقتراحات (acceptance rate) كمؤشر جودة.

ليه الـ Memory مهمة للبيزنس؟

- **Repeat contacts:** "دي تالت مرة العميل يشتكي من قطع الـ ADSL الشهر ده" → escalation أو تعويض بدل نفس الخطوات تاني.
- **Handover:** العميل كلّم على WhatsApp امبارح والنهاردة بيتصل → الموظف الجديد يشوف الملخص من غير ما يسأل من الأول.
- **CSR feedback:** لو الموظف عدّل الرد المقترح أو رفضه، ده بيتسجل ويتحول لداتا لتحسين الـ KB والـ prompts.

التكلفة مقابل العائد (مثال 50 موظف)

Item	Estimate
Contacts / month	50 CSRs × 60 contacts × 22 days ≈ 66,000
Time saved at 1 min / contact	~1,100 CSR-hours / month ≈ 6–7 full-time CSRs
Self-hosted inference	1× L40S/A100 in the cloud ≈ $600–1,800 / month, or on-prem one-off ≈ $10–20k
Conclusion	Pays back even at Egyptian salary levels if AHT drops ≥ 5–8%

Estimates are order-of-magnitude, based on public vendor claims and typical GPU prices; validate with the AHT simulation in Phase 4.

4. المنافسين: المميزات والأسعار

الأسعار دي من بحث أكتوبر 2026. أغلبها من مقالات تسعير لطرف تالت، فهي تقريبية ولازم تتراجع على صفحة الشركة الرسمية قبل أي استخدام. أسعار Google بس هي اللي من الصفحة الرسمية.

Global platforms

Product	Pricing model	Price (approx.)	Agent-assist features
Zendesk Copilot	Per-agent add-on on a Suite plan	**$50**/agent/mo + Suite Team $55 or Professional $115	Reply drafts, ticket summaries, next actions; the autonomous bot is billed per resolution
Salesforce Agentforce Service	Per user + usage credits	Editions **$25–550**/user/mo; Agentforce add-on ~$125; ~**$2**/conversation or $0.10/action	Service replies, summaries, knowledge answers, autonomous agents; data and voice cost extra
Google Agent Assist (Gemini Enterprise for CX)	Pay per use	Chat **$0.002–0.003**/message, voice **$0.03–0.05**/min, summary $0.006/session	Live suggestions, knowledge assist, smart reply, summaries, transcription; you bring the contact-centre platform
Microsoft Copilot for Service (Dynamics 365)	Bundled per user	~**$105**/user/mo (Enterprise); Premium ~$195; Contact Center ~$110	Copilot in the Dynamics desktop: answers, email drafts, summaries, Copilot Credits
Genesys Cloud CX	Per-agent tier + AI tokens	**$75–240**/user/mo	Agent Copilot, voice + digital, QA, supervisor copilot

Arabic-first players in MENA (the real local competition)

Company	Market	Offer	Price
Maqsam	Jordan, KSA, Gulf	Arabic AI contact centre: voice + WhatsApp	On request
Velents / Agent.sa	Egypt + KSA	Arabic-dialect AI on calls and WhatsApp; in-country data	On request
ZIWO	KSA (hosted in KSA)	Arabic-first AI voice agent	~$0.25/min + platform fees
Faheemly	KSA, Egypt, Gulf	Arabic customer-service AI	SAR 299 / 499 / 699 per month

التموضع (Positioning): TeleCopilot مش بديل لـ Zendesk أو Genesys. هو **Arabic-first, self-hosted agent-assist layer** بيتركب جنب أي منصة. الشركات الكبيرة تكلفتها **$75–240 للموظف في الشهر**، وتقديرنا للـ self-hosted حوالي **$12–36 للموظف** (50 موظف على GPU واحد).

- **نقط قوتنا:** اللهجة المصرية والـ Franco، الـ data residency والـ on-prem، مفيش platform lock-in (adapters + MCP)، وأدوات خاصة بالاتصالات (line test، outage، قواعد الباقات).
- **مميزات لازم تبقى موجودة لأن العملاء بيتوقعوها:** next-best-action، summaries، reply drafts، إجابات بمصادر، transcription للمكالمات، وتكلفة لكل contact.
- **مش هننافس فيه:** منصة contact center كاملة (WFM، routing، شهادات compliance).

Sources: zendesk.com/sg/pricing · richpanel.com · getmacha.com · kayako.com · cosupport.ai · cloud.google.com/agent-assist/pricing · o365hq.com · ringly.io · gartner.com (Maqsam) · middleeastainews.com (Velents) · ziwo.io · capterra (Faheemly). Intercom Fin, Arabot and Widebot were not found in this search.

5. الخطوة 1: القنوات وشاشة الموظف

دي أول خطوة لأنها بتغير شكل المشروع كله: الـ copilot مش هيستقبل سؤال، هيستقبل **محادثة** من قناة، ومعاها عميل وتيكت.

Channel options for the Egyptian market

Channel	Share in EG telco (est.)	How we integrate	Cost to us	AI skill it unlocks	Priority
Tickets / Email / web form	Medium	Own ticket tables (Postgres); IMAP inbox or form on landing page	Free	Triage, intent, priority, draft, SLA	P1
WhatsApp Business	High & growing	**Simulator first** in the exact Cloud API webhook/JSON format; later Meta's free test number (few verified recipients)	Free test tier; per-conversation fees in prod	Live assist, Franco-Arabic, voice notes (STT)	P1
Web / app chat	Medium	Own widget on a sample landing page via WebSocket; bot-first then human handover	Free	Bot → human handover, live assist	P2
Voice: call recordings	Highest volume	Upload WAV/MP3 → STT → diarisation → assist + summary	Free (GPU time)	Speech, summarisation, QA	P2
Voice: live calls	Highest volume	Browser WebRTC softphone (self-hosted LiveKit) + streaming STT; customer simulator in a 2nd tab	Free self-hosted; harder	Real-time streaming assist	P2
Facebook / Instagram DMs	Medium	Same Meta adapter as WhatsApp	Free	Reuse	P3

القرار: نبدأ بـ Tickets + WhatsApp simulator (بنفس Cloud API format الـ)، فالتحويل للـ API الحقيقي adapter واحد). في الصوت هنعمل الاتنين: voice notes وتسجيلات، ومكالمات لايف من المتصفح بـ WebRTC (LiveKit) من غير أرقام تليفون مدفوعة. حدود الـ test number المجاني لازم تتراجع وقت التنفيذ.

الواجهة: عربي وإنجليزي بالكامل (Arabic RTL mirroring + English LTR)، ملفات ترجمة `ar.json/en.json`، اختيار اللغة محفوظ لكل موظف). الستايل من "Chat UI Figma": خلفية زرقاء فاتحة، كروت بيضا، أزرق أساسي `#3 1E6FDB`، أعمدة، من غير emojis ولا شكل روبوت. التفاصيل في `docs/design/ui-reference/STYLE_GUIDE.md`.

Agent desktop wireframe

TeleCopilot Desk (Reflex) | Ziad · ● Available | Queue: 7 waiting · SLA risk 2 | AR / EN

Inbox & Conversation

- WhatsApp · Mona · "el net wa2ef men embare7" · 02:14
- Call rec. · +20 10x · Billing · 05:40
- Ticket #4821 · Router · SLA 3h
- Web chat · Ahmed · Roaming

Mona: النت واقف من امبارح والراوتر حمرا لمبة الـ LOS

CSR: ...

Customer 360 & Ticket

Mona A. · FTTH 100 Mbps · Plan "Super 250GB"

Balance OK · Last bill 450 EGP (paid)

⚠ Area outage: none · Line test: LOS

History: 2 tickets this month (router)

Ticket: [Technical ▾] [High ▾] [Assign field visit]

Memory: "Prefers WhatsApp, Egyptian Arabic, replaced ONT in Sep"

Copilot

Intent: FTTH_NO_SERVICE (0.93)

⚠ Repeat contact (3rd) → offer escalation

Next action: book field visit (tool: create_visit)

Policy: FTTH guide §4.2 · SLA 24h [cite]

Draft reply (EG Arabic): "يا أستاذة منى، آسفين جدًا..." [Insert]

[Approve visit] [Edit] [Reject]

Screen	Contents	Phase
Login + shift	Role (CSR / supervisor / admin), status, skills, languages	1
Unified inbox	All channels, SLA timers, priority, filters, assignment	2
Workspace	3 panes above; copilot updates on every new customer message	2–4
Wrap-up	Auto summary, disposition code, follow-up, CSR confirms	4
KB admin	Sources, freshness, re-index, failed extractions	3
Supervisor	Queue, AHT, FCR proxy, copilot acceptance rate, eval dashboard	6

Real KB Data (AR + EN)

6. الخطوة 2: قاعدة المعرفة من بيانات حقيقية

الـ KB الحالية 10 ملفات synthetic (حجم كل واحد ~2MB لأنها padded) + 4 صفحات من te.eg. الهدف: KB أكبر من مصادر **عامة** **حقيقية**، بصيغ متنوعة زي اللي في الشركات فعلًا، مع تاريخ وإصدار لكل مصدر.

Source (public)	Language	Formats	Content	Notes
WE (te.eg)	AR + EN	HTML, PDF	Offers, FAQs, home internet, T&Cs	Already scraped (4 pages)
Vodafone Egypt	AR + EN	HTML, PDF	Plans, roaming, eSIM, FAQs	Check robots.txt; JS-rendered pages
Orange Egypt / e& Egypt	AR + EN	HTML, PDF	Plans, bundles, terms	Same
NTRA (regulator)	AR	PDF (text + scanned)	Consumer protection, QoS, SIM registration rules	Gives "policy" authority + scanned Arabic
Router/ONT manuals (Huawei, ZTE, TP-Link)	EN	PDF with tables/images	LED meanings, reset, config	Great for troubleshooting intents
Own internal SOPs (written by us)	AR + EN	DOCX, XLSX, XML, JSON	Refund tiers, escalation matrix, disposition codes	Mark clearly as synthetic

Formats to support (mirrors a real company)

Format	Now	Add	Open-source extractor
HTML / live web	✓	JS rendering, change detection	httpx + BeautifulSoup; Playwright for JS pages
Text PDF	via Gemini OCR	Native text first, OCR only when needed	PyMuPDF, Docling
Scanned PDF (Arabic)	Gemini Vision	Local OCR	Vision/OCR model chosen in M3 (candidates: QARI-OCR, Qwen2.5-VL Arabic fine-tunes; Tesseract / PaddleOCR baselines)
DOCX / XML	✓	—	python-docx, lxml
XLSX price tables	✗	Row-aware chunks	openpyxl / pandas
FAQ JSON / CSV	✗	One Q&A per chunk	stdlib
Audio (calls)	✗	Transcripts as conversation data, not KB	ASR model chosen in M3

Synthetic data we must generate

Dataset	Size (target)	How	Quality control
Customers + plans + bills + usage	500 customers	Faker ar_EG + rules	Schema constraints
Ticket history	2,000 tickets	Templates + LLM	Intent distribution check
Conversations (EG Arabic / Franco / English / mixed)	600 conversations	LLM role-play from scenarios	Hand-check 100 → eval set
Call audio	40–60 short calls	Record ourselves + open TTS	Manual transcripts → WER
Eval Q&A per KB source	150+ questions	From ground truth	Human verified (existing HITL tool)

تنبيه: الداتا العربية المصرية للمحادثات نادرة جدًا علنًا. الـ Franco-Arabic والـ code-switching هم أصعب اختبار للموديلات المفتوحة، فلازم eval مخصص ليهم. أي scraping لازم يحترم الـ robots.txt والشروط، ويتذكر المصدر في الـ README.

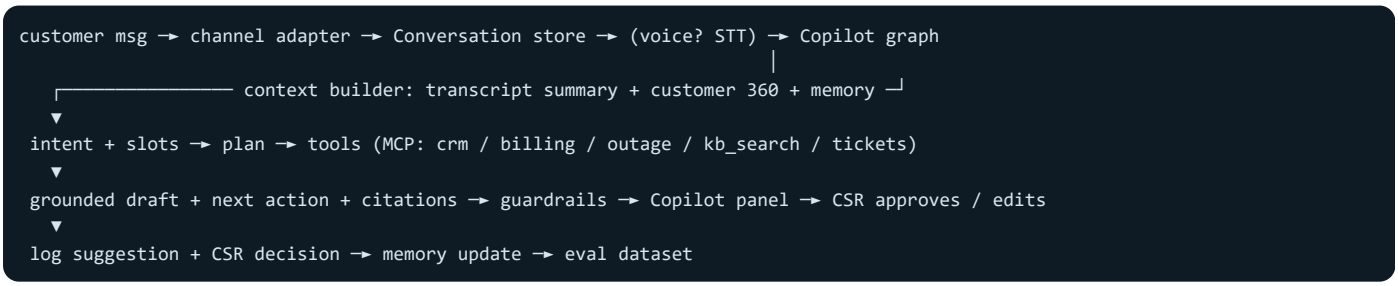
Public datasets to borrow from: Bitext customer-support (EN, partial AR), ABCD (action-based dialogues), MASSIVE (AR intents), Twitter Customer Support (EN telco brands), Common Voice / MGB-3 (Egyptian speech).

7. الخطوة 3: مسار المهارات

كل مهارة لازم تحل مشكلة حقيقية في المنتج، مش مجرد demo. الجدول ده بيربط كل مهارة بالمشكلة والموديل والمقياس.

Skill	Product problem	Open-source stack	Success metric
Speech	Transcribe calls and WhatsApp voice notes in Egyptian dialects with code-switching; who-said-what	ASR chosen in M3 (candidates: Cohere Transcribe Arabic, Egyptian Whisper fine-tunes, faster-whisper), VAD, diarisation	WER / CER on our recorded Egyptian calls
RAG	Grounded policy answers, fresh offers, AR + EN, queries in dialect / Franco	Embedding + reranker chosen in M3 (BGE-M3, Qwen3-Embedding, Arabic GATE; bge-reranker-v2-m3, Qwen3-Reranker), Qdrant hybrid	hit@3, faithfulness ≥ 0.85, freshness
Agent	Per turn: understand → fetch context → decide → draft	LangGraph + LLM chosen in M3 (candidates: Nile-Chat-4B for Egyptian + Franco, NileChat-3B, Qwen)	Task success on scenario set
Tool calling	get_customer, get_bills, check_outage, line_test, create_ticket, book_visit, apply_credit (≤ limit), escalate	vLLM with Hermes/Qwen tool parser; JSON-schema tools	Tool-selection + argument accuracy ≥ 0.9
MCP	Expose CRM / KB / tickets as standard servers any agent (or Claude Desktop) can use	Python MCP SDK, 3 servers	Same tool eval passes through MCP
Memory	Session state; per-customer long-term summary; CSR feedback	Redis (session), Postgres + pgvector (customer memory), event log	Repeat-contact detection; no stale/false memories
Context engineering	Fit transcript + customer + policies + memory into 8–32k tokens; keep latency low	Token budgeter, rolling summaries, prefix caching in vLLM	Tokens/turn, p95 latency
Eval	Know if a change made it better or worse, AR and EN separately	RAGAS, own metrics, open judge (Qwen 32B / Prometheus-2), Langfuse datasets	Dashboard + CI gate
Harness	Replay recorded conversations end-to-end, offline and in CI	pytest harness, recorded fixtures, simulated customer bot	Deterministic regression runs
Guardrails	No refunds above limit, identity check before SIM swap, PII masking	Policy rules + Presidio-style masking; LLM never writes without CSR approval	0 unsafe actions in red-team set

Agent loop (one customer message)



8. الموديلات والهاردوير والتكلفة: Local أولًا

Five Models & Local-First Stages

محتاجين **5 موديلات مفتوحة** من **Hugging Face Hub**. الاختيار في M3 بعد شغل الداتا، على **test sets بتاعتنا**: لهجات مصرية مختلفة (قاهري، إسكندراني، صعيدي، ريفي)، وعربي مخلوط بإنجليزي (code-switching)، وFranco، ومصطلحات اتصالات.

Role	Used for	Starting candidates (verify in M3)	Stage A placement
LLM	Understand, draft grounded replies, tool calls	Nile-Chat-4B (Egyptian, Arabic + Latin script), NileChat-3B, Qwen small	llama.cpp, GPU, GGUF Q4
Embedding	Search vectors	BGE-M3, Qwen3-Embedding (small), Arabic GATE models	CPU
Reranker	Re-order top results	bge-reranker-v2-m3, Qwen3-Reranker	CPU
ASR	Calls, recordings, voice notes	Cohere Transcribe Arabic (top open model on the multi-dialect Arabic ASR leaderboard), Egyptian Whisper fine-tunes, faster-whisper	GPU or CPU int8
Vision / OCR	Scanned Arabic PDFs, tables	QARI-OCR (2B, Arabic), Qwen2.5-VL Arabic fine-tunes, Tesseract / PaddleOCR	Offline batch

Criteria: quality on our evals → fits hardware → licence → speed and download size → community health. Evidence: model cards, OALL, Open Universal Arabic ASR Leaderboard, MTEB, papers; shortlist built with the Hugging Face MCP server. Details: docs/design/MODEL_SELECTION.md.

Stage	Hardware	Serving	Cost
A. Local baseline	Laptop RTX 2050 4 GB + CPU	llama.cpp (LLM), CPU embed/rerank, ASR int8, OCR as batch	$0
B. Free cloud GPU	Kaggle (T4×2 / P100, ~30 GPU-h/week), Colab free, Modal / Lightning credits	vLLM with larger variants (e.g. Nile-Chat-12B, Qwen 7B/14B), TEI, larger ASR	$0
C. Paid (cap)	RunPod / Vast spot, a few hours	Largest candidates + open judge	**≤ $10**
Fallback	—	Gemini (free tier), Cohere (trial)	$0

توقع واقعي: الـ 4GB هتشيل LLM صغير (3–4B بـ Q4) والـ ASR بالتناوب، والـ embeddings على الـ CPU. الـ baseline المحلي هيخدم عدد قليل من الموظفين (تقريبًا 3–10). ده الرقم اللي هنقارن بيه Stage B و C.

Downloads (data-saver: ask before anything > 200 MB)

What	Approx. size	When
Shortlisted local models (LLM GGUF Q4, embedding, reranker, ASR, OCR) — int8/ONNX preferred	~0.5–3 GB each	M3 (S08-03), after Ziad approves the list
Larger variants, vLLM / CUDA images	5–20 GB each	Stage B/C, on the cloud box only

Measurement

9. القياس: جودة كل خدمة + KPIs + Load Testing

كل خدمة بتتسلم ومعاها 3 تقارير: **Quality** و**Performance** و**Business KPI**. نفس التقارير بتتعاد في كل Stage علشان المقارنة تبقى عادلة.

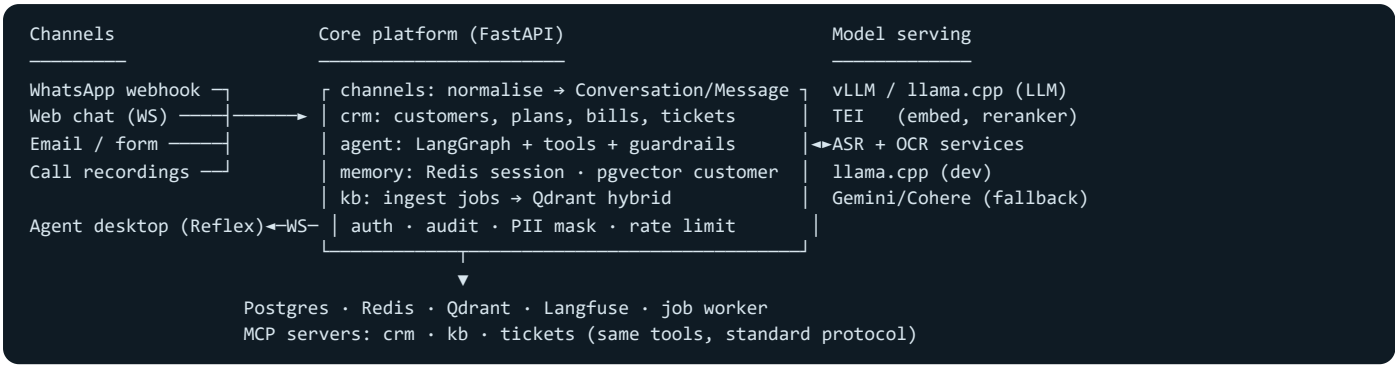
Service	Quality	Performance	Business KPI
Channels (simulator, web chat, tickets)	Delivery, ordering, no loss	msgs/s, p95 delivery, WS connections	Queue wait, SLA breaches
KB ingestion	Extraction F1, ROUGE-L, number retention	docs/min, OCR s/page	KB freshness
Retrieval	hit@3, MRR, context recall/precision (AR vs EN)	p50/p95, QPS	Policy lookup time
LLM generation	Faithfulness, relevancy, JSON validity, dialect match	tokens/s, TTFT, concurrent streams	Draft acceptance rate
Agent + tools	Tool + argument accuracy, task success	Steps/turn, p95 turn latency	AHT reduction, FCR proxy
Memory	Correct-fact recall, false-memory rate	Lookup latency	Repeat-contact detection
Speech	WER / CER (Egyptian), diarisation	Real-time factor, live latency	After-call work time
Wrap-up summaries	Key-fact coverage, correct disposition	Latency	ACW seconds saved

Business KPIs (simulated, vs the "KB search only" baseline)

KPI	How we measure it on the simulator
AHT	Scripted scenarios worked by a CSR with and without the copilot
ACW time	Time from conversation end to wrap-up saved
FCR proxy	Scenario resolved without a follow-up contact
Suggestion acceptance	Accepted / edited / rejected per suggestion (audit log)
Escalation & SLA breach rate	From ticket state in Postgres
Cost per contact	GPU-hours (or $) per 1,000 contacts

Load testing: بـ **Locust** وسيناريوهات موظف + عميل. لكل Stage بنعلن رقم واحد: **أقصى عدد موظفين في نفس الوقت** والـ p95 لرد الـ copilot أقل من 4 ثواني والأخطاء أقل من 1%. ده "max capacity" بتاع الـ Stage.

10. المعمارية وهيكلة المشروع



Proposed folder layout

```
TeleCopilotAi/
├── src/telecopilot/        one installable package (ADR-1)
│   ├── api/                FastAPI routers, schemas, websockets
│   ├── config/ core/       settings, logging, tracing, errors, security
│   ├── kb/                 extractors, chunkers, indexing, retrieval  (← today's ingestion + repositories)
│   ├── llm/                providers: llamacpp, vllm, gemini; embed/rerank: local, tei, cohere
│   ├── crm/                customers, plans, bills, tickets (Postgres)
│   ├── channels/           whatsapp (simulator + cloud adapter), webchat, email, voice
│   ├── speech/             ASR, VAD, diarisation, live-call bridge
│   ├── agent/              graph, tools, memory, prompts, guardrails
│   ├── mcp_servers/        crm, kb, tickets
│   └── worker/             background jobs
├── apps/web/               Reflex agent desktop (Arabic + English)
├── evals/                  datasets, harness, metrics, Locust load tests, reports
├── deploy/                 compose profiles, llama.cpp / vLLM / TEI configs
├── data/                   raw KB, synthetic, ground_truth
└── docs/                   PLAN, SPRINTS, design/ (ADRs, models, code guidelines, style guide)
```

مبدأ: نعمل **restructure مش rewrite**. الكود الحالي (extractors, chunkers, Qdrant repo, hybrid search) بيتنقل لـ packages/kb زي ما هو، والـ tests تفضل شغالة بعد كل نقلة.

Key technology decisions (ADRs)

Decision	Choice	Alternative
Relational DB	Postgres + Alembic + pgvector	SQLite (dev only)
Agent framework	LangGraph	Plain Python state machine
LLM serving	vLLM (cloud), llama.cpp (local)	SGLang, TGI
Embeddings / rerank serving	HF TEI	sentence-transformers in-process
Realtime	WebSocket (FastAPI)	SSE (keep for streaming text)
Jobs	arq / Celery on Redis	FastAPI BackgroundTasks
UI	Reflex (decided)	React + Vite

11. الجاهزية للإنتاج

Production Readiness (target ≥ 90%)

"Production صغير" هنا معناه: شركة واحدة، 20–100 موظف، سيرفر واحد + GPU واحد، بداتا عملاء حقيقية محمية. ده الـ checklist اللي هنقيس عليه.

#	Requirement	Today	Phase	In scope
1	Authentication + roles (CSR / supervisor / admin), JWT	✗	1	✓
2	PII masking in logs, traces and prompts (phone, national ID)	✗	4	✓
3	Audit log: every AI suggestion + CSR decision	✗	4	✓
4	Human approval for every write action (tickets, credits)	n/a	4	✓
5	Postgres + migrations + backups	✗	0–1	✓
6	Background job queue (ingest, STT, summaries)	✗	0	✓
7	Health / readiness probes for all services	partial	0	✓
8	Timeouts, retries, model fallback (vLLM → Gemini)	✗ (fail-fast only)	0	✓
9	Tracing + metrics (Langfuse + Prometheus/Grafana) + alerts	partial	6	✓
10	Rate limiting, CORS locked down, secrets outside repo	✗	1	✓
11	Eval regression gate in CI (AR + EN)	✗	6	✓
12	KB versioning, freshness, re-crawl	✗	3	✓
13	Load test per stage: max concurrent CSRs at p95 < 4 s, errors < 1%	✗	6	✓
14	Runbook + deployment docs	partial	6	✓
15	Enterprise SSO (AD/Keycloak), real CRM/ACD integration, security certification	✗	—	✗ (out of scope)

14 من 15 بند في النطاق → ≈ **90–93%** من الجاهزية لإنتاج صغير. البند 15 بيحتاج شركة حقيقية وبيئة حقيقية، فبنوثّقه كـ "integration points" بس (adapters جاهزة لـ Genesys/Salesforce).

12. طريقة الشغل

Working Agreement

Ziad = Product Owner، Claude = Tech Lead (الخطة)، وClaude Code agent بينفّذ ticket ticket. الملفات المرجعية: `docs/PLAN.md` و`docs/SPRINTS.md` و`docs/design/`.

Rule	What it means
Sprints	2 weeks, ~40 h of tickets; one branch per sprint; merge only after Ziad accepts the review
Design pack first	Every milestone: Mermaid architecture + sequence diagrams, ERD when there is data, options and reasons in plain language; Ziad approves before code
Ticket report	After each ticket: what changed, which files, why each decision (and rejected alternatives), written for learning
Code quality	SOLID, DRY, KISS/YAGNI, no anti-patterns (god classes, copy-paste, magic numbers, swallowed errors…), existing patterns (layered, factory, singleton, DI), type hints, ruff
Definition of done	Tests (no network/GPU/keys), ruff clean, docs updated, no secrets; services also need quality + performance + KPI reports
Downloads	Ask Ziad before anything > 200 MB; prefer slim images, int8/ONNX, shared caches
ADRs	10 recorded decisions (package layout, provider strategy, models, BM25, Postgres/Redis, single company, Reflex, LangGraph + MCP, Locust, data before models) — docs/design/ARCHITECTURE_DECISIONS.md

ADR = Architecture Decision Record: ملاحظة قصيرة لكل قرار تقني مهم (المشكلة، البدائل، القرار، السبب، النتايج)، علشان أي حد يفهم ليه النظام معمول كده ويغيّر القرار عن قصد.

13. الـ Milestones والمخاطر

الترتيب المتفق عليه: تنظيم الكود، ثم **الواجهة وبيانات الـ CRM**، ثم **قاعدة المعرفة وخطوط البيانات** قبل أي موديل. كل milestone يبيدأ بـ design pack. التفاصيل والـ tickets في `docs/SPRINTS.md`.

ID	Milestone	Sprints	Exit criteria
M0	Restructure & foundation	S01	New package layout, Postgres/Redis/Alembic, ingestion as a job; v1 unchanged
M1	**Agent desktop + CRM data** (Reflex, AR + EN)	S02–S04	CSR works a ticket end to end in both languages on synthetic CRM data
M2	**KB & data pipelines**	S05–S07	Real public sources, cleaning, data-quality checks, freshness, ≥ 150 verified questions
M3	Five models + retrieval baseline	S08–S09	Model study; local models running; retrieval reports
M4	Generation baseline	S10–S11	Faithfulness, JSON validity, capacity
M5	Channels	S12–S13	3 channels in one inbox
M6	Agent copilot	S14–S16	Tool accuracy ≥ 0.9; AHT simulation
M7	Speech	S17–S19	Voice notes, recordings, live calls; Egyptian WER
M8	MCP + hardening	S20–S21	Checklist ≥ 90%
M9	Stage A report	S22	Published with laptop capacity
M10	Stage B / C	S23–S24	Side-by-side benchmark

About 48 weeks part-time; re-planned at every milestone review.

Risks

Risk	Impact	Mitigation
4 GB GPU: LLM + live ASR at the same time	High	Embeddings on CPU; one heavy model on GPU; measure the limit
Internet quota	High	Big weights only on cloud boxes; int8/ONNX; ask before > 200 MB
Dialects, code-switching, Franco	Medium	Dedicated eval slices; Egyptian-tuned candidates (Nile-Chat, Egyptian ASR)
Free-tier limits change	Medium	Several providers; setup scripts; $10 reserve
No real CRM / conversation data	Medium	Synthetic + hand-checked eval slices
Scope creep / over-engineering	High	Design packs, strict exit criteria, KISS/YAGNI

Prices and limits are approximate and change often. Companion files: CLAUDE.md, docs/PLAN.md, docs/SPRINTS.md, docs/design/.